# Περιγραφή Συστήματος & Mini Documentation

## Συνολική Αρχιτεκτονική και Λειτουργία

Το σύστημα αποτελεί ένα πλήρως αυτοματοποιημένο, containerized (Docker) pipeline πρόβλεψης της Τιμής Επόμενης Ημέρας (Day-Ahead) της ολλανδικής αγοράς ηλεκτρικής ενέργειας σε ανάλυση 15-λέπτου, βασισμένο στον αλγόριθμο **LightGBM** και σε μια **Υβριδική Αυτοπαλίνδρομη Αρχιτεκτονική**. Σχεδιάστηκε ειδικά ώστε να μπορεί να εκτελείται νωρίς το πρωί, πριν από το κλείσιμο και τη δημοσίευση των επίσημων αποτελεσμάτων της αγοράς από τον ENTSO-E. Για να απεξαρτηθεί από τις τιμές που δημοσιεύονται αργά το μεσημέρι, το μοντέλο συνδυάζει τις διαθέσιμες μετεωρολογικές προβλέψεις ΑΠΕ και φορτίου με ιστορικές χρονικές υστερήσεις τιμών (**Lags 48, 72 και 168 ωρών**), οι οποίες λειτουργούν ως «άγκυρα» για το τρέχον επίπεδο τιμών και την εβδομαδιαία εποχικότητα της αγοράς.

Παράλληλα, ενσωματώνει έναν εξειδικευμένο μηχανισμό αναπλήρωσης δεδομένων (smart_impute) πάνω σε ένα ενιαίο κυλιόμενο παράθυρο 8 ημερών παρελθόντος και 2 ημερών μέλλοντος:

1. **Εσωτερικά κενά:** Τα μικρά εσωτερικά κενά έως 1 ώρας συμπληρώνονται με αυστηρά οριοθετημένη γραμμική παρεμβολή (limit_area='inside').
2. **Ιστορική μετατόπιση 24ώρου:** Τα μεγάλα μπλοκ μελλοντικών ωρών που δεν έχουν δημοσιευτεί ακόμα από το API (π.χ. η 2η ημέρα του ορίζοντα κατά την πρωινή εκτέλεση) συμπληρώνονται δυναμικά μέσω ιστορικής μετατόπισης 24 ωρών (shift(96)) από τις προηγούμενες ημέρες, εξαλείφοντας το φαινόμενο των επίπεδων γραμμών (flatlining) και των τεχνητών αλμάτων στα άκρα του ορίζοντα πρόβλεψης.
3. **Ομαλή Μετάβαση Αιολικών (Wind Blending - Νέα Προσθήκη):** Επειδή η αιολική παραγωγή (wind_on_fc, wind_off_fc) εξαρτάται από τα καιρικά μέτωπα και δεν ακολουθεί αυστηρό 24ωρο κύκλο όπως η ηλιακή παραγωγή (solar_fc), η απλή αντιγραφή του προηγούμενου 24ώρου (shift(96)) στις 00:00 CET/CEST της 2ης ημέρας μπορεί να προκαλέσει απότομη ασυνέχεια («σκαλοπάτι») αν την προηγούμενη νύχτα επικρατούσαν διαφορετικές ανεμολογικές συνθήκες. Για την αντιμετώπιση αυτού του φαινομένου, στα αιολικά χαρακτηριστικά εφαρμόζεται γραμμική μίξη (Linear Blending) ανάμεσα στην τελευταία γνωστή τιμή ανέμου της 1ης ημέρας ($W_{last}$ στις 23:45 CET/CEST) και την ιστορικά μετατοπισμένη καμπύλη ($W_{shift}$) με φθίνον βάρος $w_k = 1 - \frac{k}{N}$:

4. $W_{blended}(k) = w_k \cdot W_{last} + (1 - w_k) \cdot W_{shift}(k)$
5. Με αυτόν τον τρόπο εξασφαλίζεται απόλυτα ομαλή συνέχεια της τιμής τα μεσάνυχτα, ενώ η ηλιακή παραγωγή (solar_fc) διατηρεί αμιγώς το ημερήσιο προφίλ του shift(96) χωρίς αλλοίωση της μεσημεριανής αιχμής.

## Mini Documentation

- **Τι δεδομένα παίρνει:**
  - **Εξωγενείς Προβλέψεις (Ολλανδία & Γερμανία):** Πρόβλεψη συνολικού φορτίου ζήτησης (load_forecast), ηλιακής παραγωγής (solar_fc) και χερσαίας/υπεράκτιας αιολικής παραγωγής (wind_on_fc, wind_off_fc), καθώς

και τα αντίστοιχα διασυνοριακά μεγέθη της Γερμανίας (εφόσον είναι διαθέσιμα στο ιστορικό εκπαίδευσης).
    - **Αυτοπαλίνδρομα Χαρακτηριστικά (Υστερήσεις Τιμών):** Οι πραγματικές τιμές εκκαθάρισης της αγοράς 2 ημέρες πριν (value_lag_48h / 192 βήματα), 3 ημέρες πριν (value_lag_72h / 288 βήματα) και 1 εβδομάδα πριν (value_lag_168h / 672 βήματα).
    - **Ημερολογιακά Χαρακτηριστικά:** Ώρα (hour), λεπτό (minute), ημέρα εβδομάδας (dayofweek), μήνας (month) και δείκτης Σαββατοκύριακου (is_weekend).
- **Από πού παίρνει δεδομένα:**
    - **API Πλατφόρμας Διαφάνειας ENTSO-E:** Αυτόματη άντληση σε πραγματικό χρόνο μέσω της βιβλιοθήκης entsoe-py (query_day_ahead_prices, query_load_forecast, query_wind_and_solar_forecast).
    - **Τοπική Ιστορική Βάση (CSV):** Ιστορικό σύνολο δεδομένων (27.402 καθαρές εγγραφές 15-λέπτου μετά την αφαίρεση της αρχικής περιόδου προθέρμανσης 7 ημερών που απαιτείται λόγω του lag_168h) για την αρχική εκπαίδευση του μοντέλου.
- **Κάθε πότε συγχρονίζονται τα δεδομένα:**
    - **Εκπαίδευση:** Το εκπαιδευμένο μοντέλο αποθηκεύεται τοπικά σε αρχείο (trained_lgbm_model.pkl) και επανεκπαιδεύεται μόνο όταν ανανεωθεί το ιστορικό CSV ή διαγραφεί το αρχείο .pkl.
    - **Πραγματικός Χρόνος:** Σε κάθε εκτέλεση, το σύστημα κατεβάζει αυτόματα ένα συνεχές παράθυρο 10 ημερών (8 ημέρες πριν έως 2 ημέρες μετά την τρέχουσα ημέρα) για τον υπολογισμό των Lags και την αναπλήρωση τυχόν αδημοσίευτων προβλέψεων της 2ης ημέρας μέσω shift(96) και γραμμικής μίξης αιολικών.
- **Τι προβλέπει:**
    - Την **Τιμή Επόμενης Ημέρας της Ολλανδίας** (ζώνη προσφορών NL) σε **€/MWh**.
- **Πόσο μπροστά προβλέπει:**
    - Ορίζοντας **έως 48 ωρών (2 ημερών)** μπροστά (από το τρέχον 15λεπτο έως το τέλος της επόμενης ημερολογιακής ημέρας, 23:45 CET/CEST), σε **15-λεπτά βήματα**.
- **Κάθε πότε τρέχει:**
    - Σχεδιασμένο για **καθημερινή, πρωινή εκτέλεση** (π.χ. μέσω Docker container ή αυτόματου χρονοπρογραμματιστή), λειτουργώντας αξιόπιστα ανεξάρτητα από την ώρα δημοσίευσης των πλήρων δεδομένων Επόμενης Ημέρας του ENTSO-E.

## System Overview & Mini Documentation

**System Architecture & Overview** The system is a fully automated, containerized (Docker) pipeline for forecasting Dutch (NL) Day-Ahead electricity prices at a 15-minute resolution, powered by **LightGBM** and a **Hybrid Autoregressive + Exogenous Architecture**. It is

specifically engineered to run early in the morning, prior to the ENTSO-E Day-Ahead market gate closure and official price publication. To eliminate dependency on late-day price releases, the model combines available meteorological renewable generation (solar/wind) and load forecasts with historical price lags (**48-hour, 72-hour, and 168-hour lags**), which serve as a price-level anchor and capture weekly market seasonality.

Furthermore, the pipeline features a custom data imputation engine (smart_impute) operating over a unified rolling window (8 days of historical context plus 2 days of future horizon):

1. **Strictly Bounded Internal Interpolation:** Short internal gaps of up to 1 hour (4 steps) are resolved via strictly bounded linear interpolation (limit_area='inside'), preventing artificial extrapolation at the end of the time series.
2. **24-Hour Historical Profile Shifting:** Large blocks of unpublished future forecasts (such as the 96 steps of the second day during early-morning runs) are dynamically populated using 24-hour historical profile shifting (shift(96)), preventing artificial flatlining and boundary spikes.
3. **Linear Wind Blending (Boundary Smoothing):** Because wind generation (wind_on_fc, wind_off_fc) is driven by synoptic weather fronts rather than a strict diurnal cycle like solar generation (solar_fc), applying a raw 24-hour shift (shift(96)) at the midnight boundary (00:00 CET/CEST) can introduce an abrupt step discontinuity if wind conditions differed 24 hours earlier (e.g., causing an artificial -63.7 €/MWh price drop). To eliminate this boundary artifact, missing trailing wind horizons of length $N$ (96 steps) are smoothed via a linear blend between the last known wind forecast at the end of Day 1 ($W_{last}$ at 23:45 CET/CEST) and the historically shifted profile ($W_{shift}(k)$) using linearly decaying weights $w_k = 1 - \frac{k}{N}$:

4. $W_{blended}(k) = w_k \cdot W_{last} + (1 - w_k) \cdot W_{shift}(k)$
5. This guarantees a seamless midnight transition (00:00 CET/CEST) while preserving natural intra-day wind variability, whereas solar generation (solar_fc) retains the pure 24-hour shifted profile (shift(96)) to preserve its daytime peak.

## Mini Documentation (EN)

- **Data Inputs:**
    - **Exogenous Forecasts (NL & DE_LU):** Total demand load forecast (load_forecast), solar generation forecast (solar_fc), and onshore/offshore wind generation forecasts (wind_on_fc, wind_off_fc), along with cross-border German equivalents (dynamically included if present in the training set).
    - **Autoregressive Price Lags:** Actual historical market clearing prices shifted by 2 days (value_lag_48h / 192 steps), 3 days (value_lag_72h / 288 steps), and 1 week (value_lag_168h / 672 steps).
    - **Temporal Features:** Hour (hour), minute (minute), day of the week (dayofweek), month (month), and weekend indicator (is_weekend).
- **Data Sources:**

    - **ENTSO-E Transparency Platform API:** Automated real-time retrieval via the entsoe-py client (query_day_ahead_prices, query_load_forecast, query_wind_and_solar_forecast).
    - **Local Historical Database (CSV):** Historical dataset (27,402 clean 15-minute records after dropping the initial 7-day warm-up period required for lag_168h) used for model training.
- **Data Synchronization Frequency:**
    - **Model Training:** The trained pipeline is serialized locally (trained_lgbm_model.pkl) and only retrains when the historical CSV is updated or the .pkl artifact is removed.
    - **Real-Time Inference:** On every run, the pipeline fetches a continuous 10-day window (8 days in the past to 2 days into the future) to compute exact price lags and supply historical fallback profiles (shift(96) and Linear Wind Blending) for missing second-day forecasts.
- **Target Variable:**
    - **Dutch Day-Ahead Electricity Price (NL Bidding Zone)** expressed in **€/MWh**.
- **Forecast Horizon:**
    - Up to **48 hours (2 days) ahead** (from the current 15-minute interval through the end of the next calendar day at 23:45 CET/CEST), at a **15-minute resolution**.
- **Execution Frequency:**
    - Engineered for **daily early-morning execution** (via Docker container or automated scheduler), operating reliably even before ENTSO-E publishes the full next-day market data.